

論述リライトタスクの提案と自動評価の実現に向けて

三田 雅人^{1,2} 萩原 正人³ 坂口 慶祐⁴ 水本 智也^{5,1} 鈴木 潤^{2,1} 乾 健太郎^{2,1}

¹ 理化学研究所 ² 東北大学 ³ Octanove Labs

⁴ Allen Institute for Artificial Intelligence ⁵ フューチャー株式会社

masato.mita@riken.jp

1 はじめに

自然言語処理 (NLP) における代表的なライティング支援技術として、入力文中の文法誤りを自動的に訂正する文法誤り訂正 (Grammatical Error Correction; GEC) 技術がある。GEC 分野における初期の研究では、冠詞や前置詞などの閉じたクラスの誤りタイプを対象を絞り、個々の誤りに対して個別にモデルを構築するアプローチで研究されてきた [1, 2]。その後、閉じたクラスの誤りに限らず、動詞の態や主語と動詞の一致など、対象とする誤りのスコープを広げてきた [3, 4, 5]。

また、GEC 分野はこれまで、CoNLL-2014 [6] を始めたとしたベンチマークデータや数々の共通タスクがコミュニティに享受されることで GEC 分野は発展してきた [7, 8, 9, 6]。一方で、Sakaguchi ら [10] は、CoNLL-2014 のような誤りコード化されたコーパスや局所的な修正 (Minimal edits) に過度に依存してしまうと、結果として文法的ではあるが流暢性の低い文になってしまうという問題点を指摘した。そして、GEC の目的として、文法性だけでなく流暢性のある修正 (Fluency edits) に焦点を当てるよう再考すべきであると主張した。Sakaguchi ら [10] の推薦に応じる形で、Napoles ら [11] により、文法性および流暢性の観点で GEC モデルの出力を評価するための評価データセットである JFLEG が提案され、GEC の標準的なベンチマークとして使用されるようになった。

一方で、人間のライティングプロセスを考えた場合、文単位で文法的かつ流暢性のある作文ができるだけだけでは不十分である場合が多い。プロセスライティング教育学では、ライティングにはいくつかの段階があるとされている [12, 13]。具体的には、図 1 の左側に示すように、ライティングのプロセスとして、まず最初に文書単位で全体的な修正を行う段階 (Revision) があり、その後、文またはフレーズ




図 1 ライティングと NLP 技術の対応関係。

単位での修正 (Editing) や単語単位での細かな修正 (Proofreading) といった段階を経て作文される。これに対して、NLP (特に GEC) コミュニティでは、単語単位を中心としたスペル訂正や文法誤り訂正などの Proofreading から、フレーズや文単位の修正である Editing へと下から上へとスコープを広げてきたといえる。しかし、文書単位で大幅な修正を要する Revision に関しては未だほとんど研究が進んでいない状況である。

そこで本研究では、文書単位で英語論述の品質を向上させるための自動修正を行う論述リライト (Automated Essay Rewriting; AER) という新たなタスクを提案する。文法性・流暢性といった観点で文単位で品質を向上させることを目的とした従来の GEC タスクでは対応できない、結束性・単調性といった文を跨いだ修正や、文書全体としての明瞭さ・読みやすさを目的としたより高次の修正技術の発展・促進が本タスクの狙いである。このタスクを確立する上での課題の一つは、AER に関する研究のためのベンチマークデータが存在しないことである。このような課題を解決するために、本研究では、AER のための新たなコーパス Text Revision of ACL paper (TETRA) を構築する。

本研究の貢献は、新しいタスクの提案に加え、次の 3 点である：(1) AER のための評価用コーパスを

構築する¹⁾；(2) 構築したコーパスを基に、AER 固有の言語現象として、どのような種類の修正がどの程度観察されるかについて明らかにする；(3) 既存評価尺度を用いた評価実験を通して、AER タスクの自動評価における課題を明らかにし、今後の方向性を示す。

2 新タスク：論述リライト (AER)

1 節で述べた通り、本研究では新しいタスク**論述リライト (AER)**を提案する。最初に、AER のタスク定義をする。AER とは、与えられた文書（エッセイ）に対し、文書の内容を保存しながら文書全体としての品質を向上させるための自動修正を行うタスクである（図 1 参照）。入出力が文書であるため、文単位の処理を対象とした GEC とは異なり、文書全体の明瞭さや読みやすさといった観点から、文結合や文分割、文の並び替えなど文を跨いだ修正もタスクの対象に含まれる。

ここで、“修正”には、論述の内容レベルの修正（what to say）と表現レベルの修正（how to say）の 2 種類ある。内容レベルの修正は、表現レベルの修正と比べ、テキスト外の情報（例. 書き手の意図や論述のテーマ・トピックなど）を考慮した処理が要求されるため、一般的には表現レベルの修正よりも難易度が高いと考えられる²⁾。このことから、従来の GEC タスクにおいても、基本的には表現レベルの修正に焦点を当てている [6]。GEC よりもより大域的かつ高次の情報を要求される AER において、内容レベルの修正を含めるとタスクとして難しくなりすぎる恐れがあるため、GEC と同様に、AER でも内容レベルの修正はスコープ外とする。

3 TETRA コーパス

3.1 コーパスデザインとデータの選定

AER の評価用コーパスとして、どのように設計すべきかはそれほど自明ではない。本研究では、コーパス構築するにあたり、基本要件として次の 3 つの事項を定めた。

1. 文法誤りは修正済みであること
2. 限定的なドメインであること
3. 書き手の多様性を担保すること

1) 本研究で構築したコーパスは今後一般公開する予定である。
2) 厳密には、表現レベルの修正でさえも書き手の意図を考慮しなければ解けない場合もあるが、本稿では議論を簡単にするため言及を割愛する。

要件 1 に関しては、文法誤りは既存の GEC タスクで対象としていること、また、本研究の狙いである文章単位の品質を向上させることを目的とした大域的かつ高次の修正は、ある程度事前により低次の文法誤りが修正されていなければ観察されないという仮定に基づいている。要件 2 に関して、AER は（暗黙的な）ドメインに依存したループリックの存在を前提としており、ドメインを制限しなければ正解の修正候補が、GEC と比べて多くなり問題として難しくなりすぎる可能性があるためである。要件 3 に関しては、論文執筆などの実践的なシナリオを考えた場合、書き手の属性が母語話者/非母語話者や学生/非学生といった観点で書き手には多様性がある。そのため、コーパスのデータを収集するうえでも可能な限り偏ったサンプリングにならないよう多様性を担保することが重要であると考えられる。

上記の 3 つの要件を満たすために、次に示す方法論でデータの選定および収集を行う。まず、要件 1 および要件 2 を満たすために、ACL 論文の概要セクションおよび導入セクションを元データとして用いる。具体的には、ACL 論文の各パラグラフを 1 つの独立した文書として使用する。概要および導入セクションを使用する理由は、一般的に他のセクションよりも言説構造が重要であると考えられ、多様な修正を収集しやすいと考えられるからである。ACL 論文からアノテーション対象の論文をサンプリングする際、要件 3 を考慮して、次の 3 つの観点について多様性を担保する。

1. 会議 or ワークショップ
2. 学生 or 非学生
3. 母語話者 or 非母語話者

ここで、観点 2 および観点 3 について自動的に判別することは困難であるため、次に示す方法論で可能な限り恣意性を除外した設定でサンプリングを行った。まず最初に、ACL Anthology Sentence Corpus³⁾から、会議識別 ID を基に会議およびワークショップ論文をランダムサンプリングを行う⁴⁾。次に、サンプリングした論文を上記 3 観点の組み合わせから構成される全 8 クラスに人手で分類する⁵⁾。1 クラスにつき 1 本該当論文を割り当てるま

3) <https://github.com/KMCS-NII/AASC>

4) 本研究では、会議論文の識別 ID を P、ワークショップ論文の識別 ID を W とみなしてそれぞれ収集した。

5) 母語話者かどうかを判断する際、著者の母語を考慮するのは現実的に難しく、かつ、差別的になる恐れがあるため、本研究では筆頭著者の所属の所在地を判断基準とした。

表1 TETRA コーパスの統計量.

文書対数	425
修正文書割合 (%)	87.24
リファレンス数	3

でを1バッチとし(つまり, 1バッチにつき8論文を選定), 本研究では結果として8バッチまで行い, 合計64論文をアノテーション対象の論文として収集した.

3.2 アノテーション

選定した64本の論文に対して, アノテーションを実施するため, 3名のアノテータを雇用した. 具体的には, Upwork⁶⁾でアノテータを募集し, 品質を担保するために面接およびスクリーニングテストを経て雇用した. アノテータはいずれも英語母語話者である. アノテーションのインストラクションとして, 各修正に対して, どういった観点で品質が向上されるかについて, その修正タイプおよびコメントを自由記述で書くよう指示を与えた. 予め用意したカテゴリ群から選択させるのではなく自由記述とした理由は, AER固有の言語現象として, どのような種類の修正が存在・観察されるのか自体自明でないからである. 実際にアノテータに提示したインストラクション(抜粋)は以下の通りである.

インストラクション

For each edit, mention what aspect of the paper the edit is intended to improve. Feel free to be creative and make changes that span over multiple sentences or ones that rearrange sentences or even paragraphs if necessary. Focus instead on types of edits that improve higher-level aspects of the paper

上記手順で構築したコーパスの統計量を表1に示す.

3.3 分析

本節では, 論述リライトとは何か, 従来のGECと比べて何が違うのか, について構築したコーパスを用いて言語分析を行う. より詳細には, (1) 人間による修正はどのくらい一致するか; (2) 従来のGECではカバーされていないAER固有の修正はどのようなものがあり, またどの程度観察されるか, の2つの観点で分析を行う.

表2 修正タイプの分布.

スコープ	修正タイプ	#	%
Minimal Edits	grammar/spelling	17	9.14
Fluency Edits	punctuation/capitalization	60	32.26
	hyphenation	21	11.29
	word choice	25	13.44
	word order	1	0.54
AER	conciseness	10	5.38
	readability	17	9.14
	clarity	22	11.83
	style	4	2.15
	consistency	4	2.15
	redundancy	3	1.61
	parallelism	2	1.08

アノテータ間でどのくらい修正が一致しているかについて, 文書単位の修正であるAERにおいては, 各修正のスパンの同定およびアノテータ間でのアライメントを正確に取得すること自体が自明でなく, 困難であることが予想される. そのため, 本研究では少量のサンプルデータに対して人手でアノテータ間の修正のアライメントを取り一致率を計算する. 具体的には, ランダムに選んだ3本の論文に対して, 3人中2人以上が概ね同じ箇所を修正していたときの一致率を計算したところ, わずか33.54%という結果となった. このことから, AERはlow agreementなタスクであると言える.

次に, AER固有の修正がコーパス中にどの程度含まれるかについて分析するために, 1バッチ目に取得した論文8本に対して, アノテーションされた修正タイプを人手で集計した. その結果を表2に示す. 表2により, word choiceやhyphenationといった従来のGECタスクでカバーされる修正も観測される一方で, clarityやreadabilityなどのGECでは観測されないようなAER固有の修正も全体の33.34%と一定数含まれていることを確認した.

また, 修正タイプに関連付けられた実際に観測された修正例を表3に示す. 例えば, 表3の2段目の修正“**In** Section 4, **we** provides”は, 前方の文外文脈で“Section N”という表現を繰り返し使用されていることから, redundancy(冗長性)の観点で修正されている. これは, 文外情報を含めたより大域的な情報を要求する修正といえる. また, 3段目の修正“**In; in** a similar vein,”は, 文が長くなりすぎてしま

6) <https://www.upwork.com/>

表3 修正タイプに関連付けられた実際の修正例.

GEC scope	conciseness	clarity	readability	redundancy	style
This paper presents empirical studies and closely corresponding theoretical models of a chart parser's performance while the performance of a chart parser exhaustively parsing the Penn Treebank with the Treebank's own context-free grammar (CFG) CFG grammar. We show how performance is dramatically affected by rule representation and tree transformations, but little by top-down vs. bottom-up strategies. We discuss grammatical saturation, provide an, including analysis of the strongly connected components of the phrasal nonterminals in the Treebank, and model how, as sentence length increases, regions of the grammar are unlocked, increasing the effective grammar rule size increases as regions of the grammar are unlocked, and yielding super-cubic observed time behavior in some configurations.					
The paper is organized as follows. Section 2 presents some previous research on distributional similarity and word sense induction. Section 3 gives an overview of our method for word sense induction and disambiguation. In Section 4, we provides a quantitative evaluation and comparison to other algorithms in the framework of the SEMEVAL-2010 word sense induction and disambiguation (WSI/WSD) task. The final last section draws conclusions, and lays out a number of future research directions.					
The induction and disambiguation steps induction step and the disambiguation step are based on the same principle: words and contexts are mapped to a limited number of topical dimensions in a latent semantic word space. The intuition is that a particular sense is associated with a particular topic, so that different senses can be discriminated through their association with particular topical dimensions. In, in a similar vein, a particular instance of a word can be disambiguated by determining its most important topical dimensions.					

い, readability (読みやすさ) の観点から文分割を含めた修正がされていることが確認できる。以上より, 本コーパスには, 文法性・流暢性といった観点で文単位で品質を向上させることを目的とした従来の GEC タスクでは対応できない, 文外情報を含めたより大域的かつ高次の情報が要求される AER 固有の修正が一定数含まれていることがわかった。

4 評価

構築した AER のための新たなベンチマーク TETRA を用いて, 既存の GEC モデルを評価する。本評価実験を通して確かめたいことは次の 2 点である: (1) 現行の GEC モデルがその拡張タスクである AER タスクにおいて, どの程度解けるのか; (2) また, そのとき GEC の既存評価尺度を用いて信頼性のある評価ができるのか。

4.1 ベースモデル

実験に使用する GEC モデルとして, Kiyono ら [14] および Mita ら [15] の 2 モデルを使用する。両モデルとも GEC のベンチマーク上で世界最高水準の性能を達成しており, GEC モデルの現状を評価する上で適していると考えられる。なお, 人間による性能との比較評価を行うため, TETRA に付与されている 3 つのリファレンスのうちの 1 つを Human Expert の性能として評価する。すなわち, 本評価実験に使用する正解のリファレンス数は 2 となる。

4.2 評価尺度

評価は, GEC で広く用いられている ERRANT [16] および GLEU [17] を用いて行う。それぞれの評価尺度について, 以下に説明する。

ERRANT : BEA-2019 共通タスクの公式評価尺度にも採用され, 現在では標準的になっている。M2Scorer [18] と同様に, “修正ラティス” を用いて, モデルが行った修正を正解と最大一致するように同定する M^2 (Max Match) 法に基づき, 再現率・適合率・ $F_{0.5}$ 値を算出し評価を行う。なお, どこからどこまでを 1 つの修正と見なすかといった “修正スパンの抽出” に関する方法が M2Scorer と ERRANT とでは異なる。

GLEU : 機械翻訳タスクで最も一般的な評価尺度である BLEU [19] を文法誤り訂正用に改良した評価尺度である。GLEU は, モデル出力文 (H) と参照訂正文 (R) で一致する n -gram 数から, 入力文 (S) に現れるが参照文に現れない n -gram 数を減算することによって計算される。形式的には次式で表される。

$$GLEU+ = BP \cdot \exp\left(\sum_{n=1}^4 \frac{1}{n} \log(p_{n'})\right) \quad (1)$$

$$p_{n'} = \frac{N(H, R) - [N(H, S) - N(H, S, R)]}{N(H)} \quad (2)$$

表 4 実験結果.

モデル	ERRANT	GLEU
Human Expert	15.65	73.63
Mita ら [15]	1.53	41.30
Kiyono ら [14]	1.38	45.50
入力（無編集）	0.0	72.42

ただし、 $N(A, B, C, \dots)$ は集合間での n -gram 重なり数を表し、BP は BLEU と同様の brave penalty⁷⁾を表す。M² よりも、人手評価との相関が高いことが知られている [20].

4.3 結果・考察

表 4 に評価結果を示す。まず、ERRANT で評価したときの結果をみると、Kiyono ら [14] および Mita ら [15] の両モデルともに新たなタスクである AER においてはほとんど解けていないことがわかる。このことから、少なくとも AER は従来の GEC とは大きく性質の異なるタスクであり、かつ、より挑戦的なタスクであることが伺える。一方で、Human Expert の性能もわずか 15.65 ポイントという非常に低い性能となっている点を踏まえると、ERRANT の評価尺度自体にも問題があると考えられる。4.2 節で説明した通り、ERRANT はモデルが提示した修正スパンがリファレンスに含まれている正解修正スパンとどの程度一致しているかで評価を行う。しかし、従来の GEC と比べて、AER では文を跨ぐ修正の存在や、仮に文内における修正においてもより抜本的な修正が行われるため、正確な修正スパンの抽出およびリファレンスとの照合に失敗し、その結果見かけ上の性能を引き下げていると考えられる。

次に、GLEU で評価した場合をみると、GEC モデルは Human Expert には及ばないが、先ほどの ERRANT の結果とは異なり、一見ある程度解けているようにも見える。しかし、入力（つまり、何も編集を加えていない文書）を評価したときの性能値が、Human Expert と同程度の精度になっていることから、GLEU に関しても AER の評価尺度としてそのまま利用するには問題がある。4.2 節で説明した通り、GLEU は、基本的に入力・モデル出力・リファレンスの 3 つの文（書）における n -gram 一致率を基に計算される。ERRANT とは異なり、無編集箇所を含めた文または文書全体でリファレンスと照合をかけ

るため、同一言語内系列変換、かつ、low agreement なタスクという特徴を持った AER において、“無編集” が過大評価される傾向があると考えられる。

5 自動評価の実現に向けて

実験結果より、GEC における既存評価尺度を AER でそのまま適用するには問題があることがわかった。具体的には、文書単位で評価を行う AER においては、1) ERRANT のような修正箇所単位でリファレンスとの照合を図る手法は、修正スパンの同定およびアライメントが困難であり、また (2) GLEU のような文書単位でリファレンスとの照合を図る手法は、無編集に対して課題評価してしまう、という問題点がある。そのため、AER に特化した新たな評価尺度を用意する必要がある。上述の問題点を踏まえると、AER のための自動評価尺度を構築するには、次の事項を考慮する必要があると考える。

- リファレンスなし評価尺度の導入
- 評価設定の簡単化

low agreement というタスクの性質を考えると、ドメインを制限したとはいえ、修正候補にバリエーションが多く存在するため、リファレンスあり評価尺度自体が現実的ではない可能性があると考えられる。そのため、リファレンスを必要としないリファレンスなし評価尺度の検討も選択肢としてありえる。また、文書中の個々の修正についてその良し悪しを評価するのではなく、例えば文章全体としてリビジョン前後で改善もしくは改悪したかを当てる二値分類問題として落とし込むなど、評価の設定を簡単化させる工夫の検討も有意義であると考えられる。

6 おわりに

本研究では、文書単位で論述の品質を向上させるための自動修正を行う AER という新たなタスクを提案した。また、新タスクの提案に加え、AER のための評価コーパスを構築し、(1) AER タスクの特徴や AER 固有の言語現象について分析し、(2) また、GEC の既存評価尺度を用いた評価実験を通して、AER の自動評価における課題を明らかにし、今後の方向性を示した。今後の展望として、本研究で分析した現状の評価尺度の問題点を踏まえてより高精度な AER のための自動評価尺度の開発を進める。

7) brave penalty は入力文に対して出力文が短い場合に n -gram 適合率を減点する項である。

参考文献

- [1] Na-Rae Han, Martin Chodorow, and Claudia Leacock. Detecting Errors in English Article Usage by Non-Native Speakers. *Natural Language Engineering*, Vol. 12, No. 2, pp. 115–129, 2006.
- [2] Rachele De Felice and Stephen G. Pulman. A Classifier-Based Approach to Preposition and Determiner Error Correction in L2 English. In *COLING*, pp. 169–176, 2008.
- [3] Chris Brockett, William B. Dolan, and Michael Gamon. Correcting ESL errors using phrasal SMT techniques. In *Proceedings of the 21st International Conference on Computational Linguistics and 44th Annual Meeting of the Association for Computational Linguistics*, pp. 249–256, Sydney, Australia, July 2006. Association for Computational Linguistics.
- [4] Raymond Hendy Susanto, Peter Phandi, and Hwee Tou Ng. System combination for grammatical error correction. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 951–962, 2014.
- [5] Zheng Yuan and Ted Briscoe. Grammatical error correction using neural machine translation. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 380–386, 2016.
- [6] Hwee Tou Ng, Siew Mei Wu, Ted Briscoe, Christian Hadiwinoto, Raymond Hendy Susanto, and Christopher Bryant. The CoNLL-2014 Shared Task on Grammatical Error Correction. In *Proceedings of the 18th Conference on Computational Natural Language Learning (CoNLL 2014): Shared Task*, pp. 1–14, 2014.
- [7] Robert Dale and Adam Kilgariff. Helping our own: The hoo 2011 pilot shared task. In *Proceedings of the Generation Challenges Session at the 13th European Workshop on Natural Language Generation*, pp. 242–249. Association for Computational Linguistics, 2011.
- [8] Robert Dale, Ilya Anisimoff, and George Narroway. Hoo 2012: A report on the preposition and determiner error correction shared task. In *Proceedings of the 7th Workshop on Building Educational Applications Using NLP*, pp. 54–62. Association for Computational Linguistics, 2012.
- [9] Hwee Tou Ng, Siew Mei Wu, Yuanbin Wu, Christian Hadiwinoto, and Joel Tetreault. The CoNLL-2013 Shared Task on Grammatical Error Correction. In *Proceedings of the 17th Conference on Computational Natural Language Learning (CoNLL 2013): Shared Task*, pp. 1–12, 2013.
- [10] Keisuke Sakaguchi, Courtney Napoles, Matt Post, and Joel Tetreault. Reassessing the goals of grammatical error correction: Fluency instead of grammaticality. *Transactions of the Association for Computational Linguistics*, Vol. 4, pp. 169–182, 2016.
- [11] Courtney Napoles, Keisuke Sakaguchi, and Joel Tetreault. JFLEG: A Fluency Corpus and Benchmark for Grammatical Error Correction. In *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2017)*, pp. 229–234, 2017.
- [12] M. Buchman, R. Moore, L. Stern, and B. Feist. *Power Writing: Writing with Purpose*. No. No. 4. Pearson Education Canada, 2000.
- [13] Anthony Seow. *The Writing Process and Process Writing*, p. 315–320. Cambridge University Press, 2002.
- [14] Shun Kiyono, Jun Suzuki, Masato Mita, Tomoya Mizumoto, and Kentaro Inui. An empirical study of incorporating pseudo data into grammatical error correction. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP 2019)*, pp. 1236–1242, 2019.
- [15] Masato Mita, Shun Kiyono, Masahiro Kaneko, Jun Suzuki, and Kentaro Inui. A self-refinement strategy for noise reduction in grammatical error correction. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pp. 267–280. Association for Computational Linguistics, 2020.
- [16] Christopher Bryant, Mariano Felice, and Ted Briscoe. Automatic Annotation and Evaluation of Error Types for Grammatical Error Correction. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (ACL 2017)*, pp. 793–805, 2017.
- [17] Courtney Napoles, Keisuke Sakaguchi, Matt Post, and Joel Tetreault. GLEU Without Tuning. *arXiv preprint arXiv:1605.02592*, 2016.
- [18] Daniel Dahlmeier and Hwee Tou Ng. Better Evaluation for Grammatical Error Correction. In *Proceedings of the 2012 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2012)*, pp. 568–572, 2012.
- [19] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: A Method for Automatic Evaluation of Machine Translation. In *Proceedings of 40th Annual Meeting of the Association for Computational Linguistics*, pp. 311–318, 2002.
- [20] Courtney Napoles, Keisuke Sakaguchi, and Joel Tetreault. There’s no comparison: Reference-less evaluation metrics in grammatical error correction. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pp. 2109–2115. Association for Computational Linguistics, 2016.